

Actividad 2. Análisis clínico genómico

Bases de Datos y Recursos Bioinformáticos • MUBIO06

Caso de estudio: enfermedad de células falciformes y gen HBB

Alumno: Rubén Juárez Cádiz

Estado del documento: borrador técnico preparado para completar con evidencias reales. Antes de la entrega deben sustituirse todos los marcadores de captura por pantallazos propios de ClinVar/ENA/Galaxy/VEP.

Resumen del análisis

Se propone analizar enfermedad de células falciformes (SCD) mediante el gen HBB. El diseño integra la búsqueda fenotípica y genómica, la recuperación de datos humanos paired-end, control de calidad, limpieza, alineamiento a GRCh38, llamado de variantes en VCF y anotación funcional mediante Ensembl VEP. La variante de referencia que permite auditar la coherencia del flujo es rs334 (NM_000518.5:c.20A>T; p.Glu7Val), ampliamente asociada a HbS.

La muestra seleccionada es SRR29275383 (SCD10-Mock-2), un conjunto de datos CAST-seq dirigido al locus HBB. Este uso es académico: el pipeline ilustra principios de análisis clínico genómico, pero no constituye una prueba diagnóstica ni una validación clínica de laboratorio.

1. Inicio del estudio: enfermedad, fenotipo y gen

La enfermedad de células falciformes es una hemoglobinopatía hereditaria en la que la alteración de la beta-globina favorece la formación de hemoglobina S (HbS). El gen HBB codifica la subunidad beta de la hemoglobina adulta. NCBI Gene identifica HBB como gen codificante, localizado en 11p15.4, con tres exones; en GRCh38.p14 ocupa chr11:5225464-5227071 sobre la hebra negativa.

La variante de control es rs334. En el transcrito NM_000518.5 se expresa como c.20A>T y produce p.Glu7Val. Como HBB está en la hebra negativa, la misma sustitución se representa en el genoma GRCh38 como chr11:5227002 T>A. ClinVar Variation ID 15333 contiene múltiples clasificaciones patogénicas para enfermedad falciforme. Esta correspondencia entre coordenadas transcriptómicas y genómicas es esencial para no interpretar erróneamente el VCF.

[CAPTURA REAL • 01 • ClinVar / HBB / rs334]

Mostrar la búsqueda real donde se vean HBB, rs334 o c.20A>T/p.Glu7Val y su asociación clínica.

2. Obtención de datos de secuenciación

Se utiliza la ejecución pública SRR29275383, biblioteca SCD10-Mock-2. Es un conjunto humano paired-end descrito como CAST-seq sobre HBB en HSPC HbS mock. La elección evita utilizar una muestra de otra especie o un experimento puramente transcriptómico y mantiene una relación directa con el gen de interés.

R1: https://ftp.sra.ebi.ac.uk/vol1/fastq/SRR292/083/SRR29275383/SRR29275383_1.fastq.gz

R2: https://ftp.sra.ebi.ac.uk/vol1/fastq/SRR292/083/SRR29275383/SRR29275383_2.fastq.gz

El artículo de Moiani et al. (2024) deposita los datos CAST-SEQ del estudio bajo BioProject PRJNA1117889. En Galaxy se importan los dos FASTQ por URL, manteniendo el emparejamiento R1/R2. No se deben subir los FASTQ al repositorio GitHub.

[CAPTURA REAL • 02 • ENA/SRA SRR29275383]

Mostrar el accession, Homo sapiens y la evidencia de datos paired-end/HBB o los dos FASTQ cargados desde ENA.

3. Control de calidad inicial

Sobre los FASTQ crudos se ejecutan FastQC para R1 y R2 y, a continuación, MultiQC. La evaluación debe cubrir calidad por base, distribución de calidad por secuencia, contenido de adaptadores, secuencias sobrerrepresentadas, distribución de longitud y GC. El objetivo no es marcar módulos en rojo o verde de forma mecánica, sino decidir si existe un problema que pueda perjudicar el alineamiento o el llamado de variantes.

En este conjunto es razonable esperar presencia de adaptadores y degradación de calidad en los extremos. Cualquier porcentaje Q20/Q30, número de lecturas o valor de GC que se incorpore al informe debe copiarse de la salida real; no se preasignan valores.

[CAPTURA REAL • 03 • FastQC/MultiQC crudo]

Mostrar R1 y R2 y al menos los módulos que justifican la decisión de limpieza; anotar los valores reales observados.

4. Limpieza y reevaluación de calidad

La limpieza se realiza con fastp en modo paired-end, activando detección automática de adaptadores. Como punto de partida se recomienda filtrar bases de baja calidad alrededor de Phred 20 y descartar lecturas excesivamente cortas (<50 nt), preservando la sincronía entre pares. Si el FastQC real aconseja otra configuración, debe prevalecer la evidencia del dataset y documentarse el cambio.

Después de fastp se repiten FastQC y MultiQC. La mejora debe demostrarse comparando antes y después: menor contenido de adaptadores, perfil de calidad más estable y ausencia de una pérdida desproporcionada de lecturas. Este segundo QC es lo que convierte la limpieza en una decisión justificada, no en un paso automático.

[CAPTURA REAL • 04 • fastp + FastQC/MultiQC post-limpieza]

Mostrar el job de fastp y la comparación real de calidad antes/después.

5. Alineamiento a GRCh38

Las lecturas limpias se alinean contra el genoma humano GRCh38/hg38 con BWA-MEM o BWA-MEM2. Se recomienda utilizar la referencia completa de Galaxy, no únicamente el cromosoma 11, porque reduce el riesgo de forzar lecturas similares a HBB hacia un único cromosoma. El BAM se ordena por coordenadas y se indexa.

La interpretación incluye Samtools flagstat y, si es posible, una medida de cobertura sobre HBB. Deben registrarse el porcentaje de lecturas alineadas, pares correctamente alineados y profundidad/coertura

del locus. Una visualización en IGV/JBrowse en chr11:5225464-5227071 refuerza la evidencia y permite inspeccionar el sitio chr11:5227002.

[CAPTURA REAL • 05 • BWA + flagstat / cobertura HBB]

Mostrar el alineamiento final, las métricas reales y, si cabe, una vista del locus HBB.

6. Llamado de variantes y formato VCF

El BAM alineado se procesa con FreeBayes en modo diploide (o, alternatively, bcftools mpileup + call). Para un análisis centrado en el gen puede restringirse el llamado a chr11:5225464-5227071, manteniendo siempre GRCh38. Los filtros posteriores se justifican según la profundidad y calidad obtenidas; un ejemplo conservador es $QUAL \geq 20$, pero no debe aplicarse de forma ciega.

El VCF se interpreta por campos: CHROM y POS definen la localización; REF y ALT los alelos; QUAL la confianza; FILTER el estado de filtros; INFO incorpora métricas globales; y FORMAT describe, por muestra, GT/DP/AD/GQ u otros campos proporcionados por el caller. La variante esperada de control es chr11:5227002 T>A, rs334, pero solo puede afirmarse que “se detecta” si aparece realmente en el VCF de Galaxy.

[CAPTURA REAL • 06 • VCF de HBB]

Mostrar cabecera/campos y las variantes reales. Si aparece rs334, debe verse la línea y sus métricas de soporte.

7. Análisis de variantes con Ensembl VEP

El VCF se descarga desde Galaxy y se carga en Ensembl VEP seleccionando Homo sapiens y GRCh38. Se activan HGVS, variantes conocidas, asociaciones fenotípicas/ClinVar, frecuencias poblacionales y predictores funcionales cuando estén disponibles. La priorización combina consecuencia funcional, calidad del VCF, coincidencia con variantes conocidas y evidencia clínica.

Si el VCF contiene rs334, el control de coherencia es que VEP lo relacione con HBB y una consecuencia missense, con nomenclatura compatible con p.Glu7Val. La evidencia clínica consolidada en ClinVar tiene más peso que predictores in silico aislados. Las variantes adicionales deben comentarse según consecuencia y evidencia, evitando atribuir patogenicidad sin soporte.

[CAPTURA REAL • 07 • Ensembl VEP]

Mostrar la salida real con gene, consequence, HGVS/existing variation y evidencia clínica relevante.

8. Discusión integrada y limitaciones

El flujo conecta una hipótesis fenotipo-gen con datos de secuenciación y una interpretación de variantes. La elección de HBB aporta una referencia biológica clara, pero el dataset procede de un contexto experimental de edición génica/CAST-seq, por lo que no debe interpretarse como un caso clínico

diagnóstico convencional. Su utilidad aquí es metodológica: permite practicar un pipeline completo con una variante de control conocida.

La principal fuente de error potencial es mezclar ensamblajes: GRCh37 sitúa la variante en 11:5248232 T>A, mientras GRCh38 la sitúa en chr11:5227002 T>A. Todo el pipeline propuesto se mantiene en GRCh38. Otras limitaciones son los sesgos de un ensayo dirigido, la dependencia de parámetros de trimming/caller y la necesidad de contextualizar frecuencia poblacional y evidencia clínica.

9. Trazabilidad de la rúbrica

Criterio	Peso	Evidencia	Estado
Búsqueda fenotípica	10 %	ClinVar/NCBI Gene + captura 01	Preparado
Datos de secuenciación	10 %	ENA/SRA + captura 02	Preparado
QC	20 %	FastQC/MultiQC + captura 03	Pendiente ejecución
Limpieza	10 %	fastp + captura 04	Pendiente ejecución
Alineamiento	15 %	BWA + flagstat/coverage + captura 05	Pendiente ejecución
VCF	15 %	FreeBayes/bcftools + captura 06	Pendiente ejecución
VEP	20 %	Anotación + captura 07	Pendiente ejecución

10. Checklist previo a la entrega

- ☐ Sustituir los siete marcadores por capturas reales y legibles.
- ☐ Anotar valores reales de FastQC, trimming, flagstat, cobertura y VCF.
- ☐ Mantener GRCh38 en alineamiento, VCF y VEP.
- ☐ Verificar que cualquier mención a rs334 como variante detectada está respaldada por el VCF real.
- ☐ Comprobar que el PDF final no supera 20 páginas, usa Calibri 12 e interlineado simple.
- ☐ Eliminar datos personales innecesarios de capturas de Galaxy antes de entregar.

Referencias

NCBI Gene. HBB hemoglobin subunit beta [Homo sapiens], Gene ID 3043.
<https://www.ncbi.nlm.nih.gov/gene/3043>

NCBI ClinVar. Variation ID 15333, HBB c.20A>T (p.Glu7Val), rs334.
<https://www.ncbi.nlm.nih.gov/clinvar/variation/15333/>

Moiani A, Letort G, Lizot S, et al. Non-viral DNA delivery and TALEN editing correct the sickle cell mutation in hematopoietic stem cells. Nature Communications. 2024;15:4965. doi:10.1038/s41467-024-49353-3.

Ensembl. Variant Effect Predictor (VEP). <https://www.ensembl.org/Tools/VEP>

Galaxy Training Network. A short introduction to Galaxy / Introducción a Galaxy.
<https://training.galaxyproject.org/>

McLaren W, Gil L, Hunt SE, et al. The Ensembl Variant Effect Predictor. Genome Biology. 2016;17:122. doi:10.1186/s13059-016-0974-4.